

Projeto T4 — Catalogação e Tagging Automático de Imagens de Moda

Diogo Dias (PG60245)¹, Eduardo Vilaça (PG60252)¹, Nuno Ni (PG60285)¹,
and Simão Silva (PG60393)¹

¹ Grupo 6

Projeto de Inteligência Artificial
Mestrado em Inteligência Artificial — Universidade do Minho

Abstract. A catalogação manual de peças de vestuário na indústria têxtil é um processo moroso, dispendioso e suscetível a erros humanos. Este projeto, desenvolvido como resposta à proposta T4 (“Catalogação e Tagging Automático de Imagens de Moda”) do enunciado da unidade curricular de Projeto de Inteligência Artificial do MIA (Mestrado em Inteligência Artificial), tendo como referência os desafios lançados pelo **CITEVE**, propõe uma plataforma inteligente, o **DeepFashion AI**, desenhada para automatizar a extração de metadados complexos a partir de imagens de moda. A solução implementa uma arquitetura modular que permite ao utilizador alternar dinamicamente entre múltiplos motores de predição. O pipeline principal assenta em VLMs (Modelos de Visão-Linguagem) do estado da arte, especificamente a framework CLIP (e a sua variante otimizada **Fashion-CLIP**), operando sob o paradigma de Zero-Shot Learning.

Para consubstanciar a pesquisa e estabelecer um **benchmark** arquitetural rigoroso, o projeto segue uma linha de investigação que compara três paradigmas evolutivos: Redes Neurais Convolucionais (CNNs) tradicionais, modelos contrastivos (Fashion-CLIP) e Modelos de Linguagem Multimodais de Grande Escala (LLaVA). Estes modelos são submetidos a uma validação quantitativa realizada sobre o **dataset** original dos modelos e a uma avaliação empírica em cenários de complexidade visual crescente (peças em 2D, contexto de e-commerce humano e imagens multi-indivíduo). A plataforma final, desenvolvida em Flask com pipelines enriquecidos por **Test-Time Augmentation** (TTA), demonstra a superioridade de arquiteturas multimodais no tratamento de ruído de fundo e sobreposição semântica no setor têxtil. O estudo conclui formalmente que a arquitetura vencedora para o **pipeline** de produção é o **Fashion-CLIP**, por oferecer o melhor compromisso (**trade-off**) entre a exatidão multiatributo e uma latência de operação instantânea.

Keywords: Inteligência Artificial · Visão Computacional · CNN · CLIP · LLMs Multimodais · Indústria Têxtil · Extração de Metadados

1 Introdução

A transformação digital no setor têxtil e de moda exige sistemas de informação cada vez mais ágeis e integrados. No paradigma atual do e-commerce e da gestão

avançada de inventários, a capacidade de categorizar peças de roupa de forma **padronizada e automática** é um fator crítico de competitividade. As empresas de retalho e marcas de moda deparam-se diariamente com o desafio de processar fluxos massivos de dados visuais, onde a catalogação humana se revela um estrangulamento operacional. Instituições tecnológicas como o CITEVE assumem um papel fulcral na transição digital deste setor, procurando fornecer às marcas ferramentas automatizadas para mitigar este problema.

O problema central da classificação de moda reside na elevada complexidade intra-classe e na variabilidade ambiental das imagens. Uma única peça de vestuário possui múltiplos atributos intrínsecos que necessitam de ser dissecados simultaneamente: o tipo de corte ou silhueta (e.g., vestido, calças), a paleta de cores dominante e o tipo de padrão ou textura (e.g., floral,xadrezado, liso) [1]. Adicionalmente, as imagens reais apresentam frequentemente fundos ruidosos, iluminação variável e oclusões causadas pela pose dos modelos humanos.

O presente projeto documenta o desenvolvimento e a arquitetura do **Deep-Fashion AI**, uma plataforma web desenhada para atuar como uma **PoC** (prova de conceito) na resolução deste problema de negócio. O foco desta investigação incide não apenas na entrega de uma ferramenta funcional de extração de metadados para JSON, mas primordialmente na análise estrutural e no **benchmark** de diferentes paradigmas de Inteligência Artificial para a Visão Computacional.

A narrativa tecnológica deste relatório está estruturada numa **storyline** evolutiva e comparativa:

1. **Garantia e Processamento de Dados:** A base do projeto assentou na organização do **dataset DeepFashion** [1], recorrendo a módulos de validação robustos para garantir a exclusão de imagens corrompidas e a deduplicação matemática através de algoritmos de hashing. Foi ainda necessário intervir na recuperação de etiquetas corrompidas na origem, desenvolvendo heurísticas para purgar metadados ruidosos e restaurar o mapeamento técnico.
2. **Investigação do Estado da Arte:** Condução de uma **revisão bibliográfica** aprofundada sobre a evolução dos paradigmas de Visão Computacional na última década. Foi através desta análise teórica que mapeámos a transição dos modelos discriminativos tradicionais para as redes multimodais e generativas, fundamentando cientificamente a seleção das três arquiteturas base avaliadas neste projeto como representantes de cada geração tecnológica.
3. **O Paradigma Tradicional (CNNs):** Para estabelecer um **baseline** de arquitetura clássica identificada no Estado da Arte, foi integrada e avaliada uma Rede Neuronal Convolucional (ResNet-50) de código aberto, pré-treinada especificamente no dataset **DeepFashion** [2]. Esta abordagem documenta o estrangulamento prático dos modelos discriminativos em ambientes multi-atributo, uma vez que a rede opera estritamente na previsão da silhueta (tipo de peça), revelando-se incapaz de extrair texturas ou cores.
4. **A Solução Base (Zero-Shot Learning):** Como resposta direta às limitações das CNNs, a arquitetura central do pipeline adota o modelo multimodal contrastivo **Fashion-CLIP** [3]. Ao contrário dos métodos tradicionais de aprendizagem supervisionada, o paradigma **zero-shot** elimina a necessidade

de treinar um modelo para cada novo padrão ou cor, realizando o mapeamento direto entre representações visuais e textuais. Esta abordagem foi reforçada com um estudo sobre o impacto de **Test-Time Augmentation** (TTA).

5. **A Fronteira Generativa (LLaVA):** Como cenário de exploração do Estado da Arte, a plataforma foi arquitetada de forma modular no backend (**Flask** [4]) para suportar a troca dinâmica de motores de inferência. Implementou-se a integração local do LLaVA (via Ollama [5]), permitindo contrapor a extração vetorial do CLIP à capacidade raciocínio lógico-visual e **prompting** natural dos LLMs [6].
6. **Estudo Empírico:** Avaliação laboratorial dos modelos face a três níveis de complexidade fotográfica (2D, em modelo humano e em multidão). Este ensaio avalia qualitativamente a assimetria entre a CNN (limitada à categoria) e os modelos multimodais (extração integral de múltiplos atributos simultâneos), provando a resiliência arquitetural face ao ruído de fundo.

Para garantir a eficácia iterativa do desenvolvimento tecnológico, todo o ciclo de vida do projeto foi gerido sob a metodologia **SCRUM**, estruturando o planeamento, a investigação teórica e a implementação técnica em **Sprints** contínuos, cujos artefactos se encontram documentados no ficheiro **Backlog_PIA.docx**. Através desta análise comparativa e metodológica, o relatório delineia uma resposta técnica escalável e fundamentada para a modernização do inventário têxtil.

2 Enquadramento Teórico e Estado da Arte

O problema da catalogação automática de moda e do reconhecimento de atributos visuais complexos tem acompanhado a evolução histórica da **Visão Computacional**. Para fundamentar as escolhas arquiteturais do **DeepFashion AI**, é imperativo analisar a transição metodológica desde os modelos discriminativos clássicos até aos recentes paradigmas multimodais generativos.

2.1 A Era das CNNs (Redes Neurais Convolucionais)

Durante a última década, a extração de características visuais foi dominada pelas **CNNs** (Redes Neurais Convolucionais), impulsionadas por arquiteturas de referência como a ResNet [7] e a VGG. As CNNs operam sob um paradigma de aprendizagem estritamente supervisionada. O modelo aprende a extrair mapas de características (**feature maps**) locais através da aplicação de filtros convolucionais hierárquicos: as primeiras camadas detetam arestas e gradientes de cor, enquanto as camadas mais profundas agregam estas características para formar representações semânticas complexas, como mangas de camisas ou colarinhos.

Na literatura focada no retalho têxtil, as arquiteturas baseadas em CNNs ditaram o estado da arte inicial. Trabalhos seminais, como a arquitetura **FashionNet** — introduzida de forma adjacente ao próprio **dataset** DeepFashion [1] —, demonstraram a viabilidade de utilizar redes profundas para prever **landmarks** corporais (ex: golas, bainhas) e categorias de vestuário de forma interligada.

Apesar de se revelarem ferramentas eficazes na identificação topológica de silhuetas estruturadas, como comprovado pelos ensaios analíticos do nosso grupo, onde uma arquitetura convolucional atingiu 68% de exatidão topológica (Top-1) utilizando a ResNet-50 no **DeepFashion**, as CNNs clássicas apresentam estrangulamentos críticos em ambientes industriais multi-atributo:

- **O Paradigma de Conjunto Fechado (Closed-Set):** Uma CNN é treinada para classificar um número fixo de classes na sua camada densa final (**Fully Connected Layer**). A introdução de uma nova classe de vestuário exige a alteração da arquitetura e um processo computacionalmente dispendioso de retreino ou **fine-tuning**.
- **Dependência Massiva de Dados Anotados:** O treino eficaz de uma CNN exige centenas de milhares de imagens. No domínio da moda, onde as tendências e padrões mudam sazonalmente, manter um **dataset** atualizado e com anotações perfeitas é financeiramente insustentável.
- **A dificuldade no Multi-Task Learning:** Na catalogação industrial, uma única peça exige a extração simultânea da sua cor, padrão e silhueta. Estudos avançados na área de recuperação de imagens de moda [8] evidenciam que forçar uma única CNN a classificar todos estes parâmetros em simultâneo exige arquiteturas complexas de **Multi-Task Learning** (redes com múltiplas cabeças). Esta topologia obriga ao balanceamento frágil de múltiplas funções de perda (**Loss Functions**), o que frequentemente induz conflitos nos tensores partilhados e leva à degradação dramática da precisão num dos atributos face ao ruído de fundo.

2.2 A Mudança de Paradigma: Vision Transformers (ViTs)

A verdadeira revolução na modelação visual iniciou-se com a transição do mecanismo de convolução para o mecanismo de atenção (Self-Attention). Originalmente desenhada para o **NLP** (Processamento de Linguagem Natural) [9], a arquitetura Transformer foi adaptada para a visão [10] através do **ViT** (Vision Transformer).

Em vez de deslizar filtros sobre a imagem, o **ViT** divide a imagem numa grelha de patches (ex: 16x16 píxeis), achatando-os em vetores lineares que são tratados como “palavras” numa frase. O mecanismo de self-attention permite que o modelo compreenda o contexto global da imagem desde a primeira camada, estabelecendo relações de longo alcance entre diferentes áreas da fotografia. Esta flexibilidade e poder de representação tornaram o **ViT** no motor de extração visual de eleição para os modelos fundacionais subsequentes.

2.3 Modelos de Visão-Linguagem e Aprendizagem Contrastiva (CLIP)

Para colmatar a rigidez da aprendizagem supervisionada clássica, introduziram o **CLIP** (Contrastive Language-Image Pre-training) [11]. O **CLIP** abandona a classificação tradicional e adota uma aprendizagem baseada em pares de imagem-texto, utilizando **datasets** recolhidos em grande escala da Internet.

A arquitetura do CLIP divide-se em dois componentes a atuar em paralelo:

1. Um **Image Encoder** (baseado num ViT ou ResNet).
2. Um **Text Encoder** (baseado num Transformer text-only).

O treino é executado de forma contrastiva: o objetivo matemático do modelo é maximizar a similaridade de cosseno (**cosine similarity**) entre o **embedding** de uma imagem e o **embedding** da sua descrição textual correspondente no espaço latente multidimensional, forçando, em simultâneo, a repulsa vetorial face às descrições incorretas presentes no mesmo lote (**batch**) de treino.

Zero-Shot Learning na Moda: O CLIP desbloqueia a capacidade de Zero-Shot Learning. Ao contrário de uma CNN, permite que o sistema identifique classes que nunca viu explicitamente durante um treino curado. Basta fornecer ao Text Encoder um dicionário arbitrário de descrições e calcular qual se aproxima mais da imagem fornecida.

Para este projeto, identificámos o **Fashion-CLIP** [3] como a arquitetura SOTA otimizada. Sendo alvo de **fine-tuning** com o dataset Farfetch, este modelo mapeia com superior precisão a taxonomia têxtil, solucionando a necessidade de extrair cor, tecido e padrão sem a rigidez topológica das redes clássicas.

2.4 A Fronteira Generativa: MLLMs (Grandes Modelos de Linguagem Multimodais)

A mais recente iteração do Estado da Arte expande o horizonte para lá do mapeamento vetorial, dotando os sistemas de inteligência generativa e capacidade de raciocínio lógico. Os **MLLMs** (Multimodal Large Language Models), como o GPT-4V ou o LLaVA [6], conectam diretamente um codificador visual poderoso (frequentemente o **Vision Encoder** do próprio CLIP) a um **LLM** (Large Language Model).

Através do processo de Visual Instruction Tuning, modelos como o LLaVA aprendem a utilizar o **embedding** da imagem como um **prompt** contextual. O LLM atua então como um descodificador, permitindo que a interação seja feita através de Questão-Resposta (VQA - **Visual Question Answering**). Neste paradigma, o sistema não se limita a associar “camisola de lã” à imagem; ele consegue responder a questões inferenciais complexas, como: “Qual a cor secundária dos botões desta peça e a que macro-categoria de uso pertence?”.

A eficácia deste paradigma na catalogação têxtil tem sido corroborada por estudos recentes de adaptação de Modelos de Visão-Linguagem para ambientes de **e-commerce**. Investigações atuais demonstram que arquiteturas baseadas no LLaVA alcançam desempenhos de topo em **benchmarks** de Compreensão Profunda de Moda (**Deep Fashion Understanding**), executando o que na literatura se designa por **Dynamic Attribute Extraction**, a capacidade de enumerar e estruturar visualmente todos os atributos de uma peça de roupa num formato tabular ou JSON, sem a necessidade de um esquema ou base de dados restritivos [12].

Apesar desta enorme flexibilidade semântica e da superioridade no isolamento de atributos complexos, a adoção nativa de **MLLMs** na indústria têxtil (e especificamente em infraestruturas como a do CITEVE) enfrenta constrangimentos

operacionais críticos. A dependência de aceleradores de **hardware** de topo com elevada capacidade de memória gráfica (VRAM) e, sobretudo, a severa latência de geração de respostas (**Time-to-First-Token**), tornam a sua aplicação impraticável para o processamento massivo e instantâneo de catálogos industriais.

2.5 Síntese Evolutiva das Arquiteturas

Para consolidar a revisão bibliográfica e mapear o progresso metodológico da Visão Computacional na última década, apresenta-se um sumário evolutivo das abordagens aplicadas à catalogação têxtil.

A cronologia detalhada na tabela abaixo evidencia a superação gradual do maior estrangulamento da área: a dependência massiva de **datasets** anotados manualmente. O paradigma evoluiu de redes convolucionais estritas (limitadas ao **Closed-Set** de treino) para a flexibilidade do raciocínio multimodal, culminando nas atuais arquiteturas de instrução visual generativa.

Tabela 1. Síntese da evolução do Estado da Arte em **Computer Vision** aplicado à extração de atributos de moda.

Modelo	Ano	Arquitetura	Algoritmo/Paradigma	Evolução e Impacto no Problema
FashionNet (Deep-Fashion)	2016	CNN (Convolutio-nal)	Supervisionada (Discriminativo)	Lançou a fundação do reconhe-cimento visual de categorias e landmarks , mas limitado pela rigidez da taxonomia fe-chada.
ResNet-50	2016	CNN (Resíduos)	Supervisionada (Discriminativo)	Estabeleceu o baseline clás-sico do nosso estudo. Elevada exatidão para a silhueta prin-cipal, mas colapsa no processa-mento Multi-Task conjunto.
ViT (Vision Trans-former)	2020	Transformer (Mecanismo de Atenção)	Atenção Global (Self-Atten-tion)	Ponto de viragem. Substituiu a convolução pela análise de patches , permitindo à IA compreender o contexto global e as relações de longa distância na imagem.
CLIP	2021	ViT + Text Transformer	Aprendizagem Contrastiva (Zero-Shot)	Mudança de paradigma estru-tural. Alinhamento vetorial de Imagem e Texto, libertando os modelos da necessidade de re-treino para novas categorias.
Fashion-CLIP	2022	ViT + Text Transformer	Contrastiva com Fine-Tuning	O motor otimizado para retalho da nossa PoC . Redefinição do espaço latente para o jargão têxtil, permitindo a extração instantânea de cor, padrão e silhueta.
LLaVA/MLLMs	2024	ViT + LLM (Generativo)	Visual truction ning	Ins-Tu- A fronteira atual. Integra ra-ciocínio profundo e geração livre de metadados (JSON sem esquema rígido), mas severa-mente penalizado pela latência em produção.

3 Análise, Tratamento e Recuperação de Dados

A base de um pipeline de Machine Learning robusto reside na qualidade do seu repositório de dados. O projeto foi desenhado para utilizar o **DeepFashion** [1], um **dataset** de referência que contém anotações detalhadas de atributos, categorias e **bounding boxes**. No entanto, a sua ingestão para o nosso pipeline exigiu um tratamento de engenharia profundo. O dataset utilizado como base é o DeepFashion versão Category and Attribute Prediction, especializado em avaliar a performance de modelos no que toca à classificação de categorias de roupa e atributos presentes. Este dataset agrupa 289222 imagens de roupa e 1000 atributos distintos, resultado num vetor de 1000 valores por imagem indicando a presença/ausência do atributo. Dado o teor elaborado do vocabulário utilizado na designação dos atributos optamos filtrar certos tipos de atributos. Sem validação alguma adicionamos um atributo de cor para observarmos que modelos são capazes de inferir a cor da peça.

Tabela 2. Tipos de Categoria (50 no total)

Tipo	Categorias	N.º de categorias
Upper-body	Anorak, Blazer, Blouse, Bomber, Button-Down, Cardigan, Flannel, Halter, Henley, Hoodie, Jacket, Jersey, Parka, Peacoat, Poncho, Sweater, Tank, Tee, Top, Turtleneck	20
Lower-body	Capris, Chinos, Culottes, Cutoffs, Gauchos, Jeans, Jeggings, Jodhpurs, Joggers, Leggings, Sarong, Shorts, Skirt, Sweatpants, Sweatshorts, Trunks	16
Full-body	Caftan, Cape, Coat, Coverup, Dress, jumpsuit, Kaftan, Kimono, Nightdress, Onesie, Robe, Romper, Shirdress, Sundress	14

Tabela 3. Tipos de Atributo (554 atributos + 18 cores 572 no total)

Atributo	Descrição	Exemplos de valores	ID
Textura	Padrão visual e estampagem do tecido	Palm, Colorblock, Plaid, Striped, Floral, Graphic, Solid, Animal Print, Paisley, Camouflage, Geometric	attr1
Material	Tipo de fibra ou material usado na peça	Leather, Tweed, Denim, Cotton, Lace, Silk, Knit, Mesh, Velvet, Chiffon, Wool, Polyester	attr2
Forma/Silhueta	Corte, comprimento e silhueta da peça	Crop, Midi, Maxi, Mini, A-line, Bodycon, Flared, Oversized, Slim, Boxy, Wrap, Peplum	attr3
Detalhe/Acabamento (excluído)	Elementos decorativos e acabamentos específicos	Bow-F, Fringed-H, Lace-Trim, Zipper, Pocket, Button, Ruffle, Slit, Embroidery, Sequin, Cutout	attr4
Estilo (excluído)	Estética geral ou referência temática da peça	Mickey, Baseball, Bohemian, Preppy, Vintage, Athletic, Casual, Formal, Military, Romantic, Grunge	attr5
Cor (adicionado)	Cor da peça	black, white, red, blue, green, yellow, beige, navy, grey, brown, pink, purple, orange, burgundy, teal, olive, ivory, coral	attr6

3.1 Aquisição e Garantia de Qualidade

O descarregamento do **dataset** foi automatizado através do script `setup_dataset.py`, consumindo ficheiros diretamente de instâncias de armazenamento em cloud (Google Drive).

Para garantir a limpeza dos dados antes da inferência, desenvolveu-se o módulo `dataset_manager.py`. Este módulo implementou os seguintes mecanismos de segurança:

- **Validação de Integridade e Formato:** Todas as imagens do diretório `img/` são submetidas a uma validação via biblioteca PIL (Python Imaging Library), garantindo que os ficheiros não estão corrompidos e forçando a conversão para canais RGB.
- **Filtro de Resolução:** Foram excluídas amostras com resolução inferior a 224x224 pixels, que é o limite mínimo de entrada para o **Vision Transformer** do modelo CLIP.
- **Deduplicação Baseada em Hash:** A presença de amostras duplicadas entre conjuntos de treino e teste induz o fenómeno de **data leakage**, inflacionando artificialmente as métricas de avaliação empírica. Para mitigar este risco, implementou-se um algoritmo de deduplicação assente no cálculo de um **hash** criptográfico (MD5) sobre os primeiros 4096 **bytes** (4KB) da assinatura binária de cada imagem. Este método garante a identificação e purga de cópias exatas de forma determinística, independentemente da nomenclatura do ficheiro original.

3.2 O Problema da Corrupção de Metadados e Recuperação Lexical

Durante a integração dos metadados textuais (essenciais para definir a taxonomia-alvo do **Text Encoder** do CLIP), deparámo-nos com um obstáculo. Ficheiros cruciais do **dataset**, como o `list_attr_cloth.txt` e o `list_category_cloth.txt`, sofreram corrupção de formato durante a extração das instâncias de armazenamento em **cloud**. Os ficheiros foram encapsulados como páginas web (`text/html`), embutindo megabytes de **scripts** iterativos e folhas de estilo (CSS) que inviabilizavam a conversão direta das **labels** em tensores estruturados.

Em vez de realizarmos limpeza manual (o que comprometeria a reprodutibilidade do projeto), desenvolvemos uma solução de **Label Recovery** (`recover_labels.py`).

A rotina de recuperação atua em três fases consecutivas de limpeza:

1. **Purga Estrutural:** Remoção de blocos completos de `<script>` e `<style>` utilizando Expressões Regulares (Regex) com suporte a múltiplas linhas.
2. **Remoção de Tags HTML:** Supressão de qualquer **tag** envolvente (ex: `<div>`, `<span>`), isolando o texto cru.
3. **Extração Heurística:** O script percorre as linhas resultantes à procura do padrão específico do **DeepFashion**, nomeadamente: `<nome do atributo>` seguido de um ou mais espaços e do `<tipo_numérico>` (e.g., “striped 1” ou “black 6”). Foram implementadas proteções contra falsos positivos, garantindo que o nome do atributo cumpre comprimentos lógicos (menor que 80 caracteres) e se inicia por caracteres alfanuméricos.

Esta abordagem automática permitiu recuperar o dicionário completo do sistema, gravando-o em ficheiros limpos e restabelecendo o fluxo funcional do **DeepFashion AI** sem intervenção humana adicional.

4 Exploração do Paradigma Tradicional: CNNs (Redes Convolucionais)

Para estabelecer um baseline comparativo rigoroso face à solução multimodal, o grupo avaliou uma **CNN** (Rede Neuronal Convolutacional) clássica. O objetivo desta prova de conceito empírica foi medir o desempenho e as limitações de um modelo discriminativo SOTA (**State of the Art**) desenhado especificamente para a classificação de vestuário, contrastando-o com a flexibilidade multimodal dos modelos CLIP e MLLMs.

4.1 Integração do Modelo Base (ResNet-50 no DeepFashion)

A nossa avaliação assentou na integração de um modelo de um repositório de código aberto (FarnooshGhadiri/Cloth_category_classifier) [2]. Este repositório disponibiliza uma arquitetura **ResNet-50**, pré-treinada no **dataset** DeepFashion.

O modelo foi configurado e submetido ao nosso script de testes (`eval_cnn.py`), operando sobre o **test set** oficial do DeepFashion, que é composto por imagens de alta resolução distribuídas por 50 categorias morfológicas distintas. Para isolar o desempenho geométrico da rede e garantir uma comparação metodologicamente justa com as restantes arquiteturas, a avaliação quantitativa focou-se exclusivamente na cabeça de classificação da Categoria (Tipo de Peça).

4.2 Resultados Empíricos e Exatidão por Classe

Os dados extraídos do **benchmark** confirmam a eficácia matemática deste paradigma em condições de domínio fechado: a ResNet-50 atingiu uma exatidão (**Top-1 Accuracy**) de 68.00% na predição exata da categoria, e uma excelente exatidão **Top-5** de 93.20%, aliada a uma latência inferencial de apenas 4.1 milissegundos.

4.3 Análise Crítica: A Limitação Estrutural e o “Context Blending”

Esta validação empírica evidenciou a insuficiência dos modelos puramente convolucionais quando confrontados com a natureza multiatributo e o rigor semântico exigidos pela catalogação de moda. Durante a nossa fase exploratória de **Multi-Tasking**, constatou-se que exigir a esta mesma CNN a extração conjunta de múltiplos parâmetros em simultâneo (Categoria, Padrão e **Fit**) faz com que a sua eficácia global colapse drasticamente para valores na ordem dos 10%.

Esta degradação profunda explica-se por duas barreiras estruturais:

1. **Context Blending (Mistura de Contexto):** Conforme advertido na literatura destes classificadores, a presença de ruído de fundo ou sobreposição de peças diferentes no mesmo humano funde os gradientes matemáticos da rede. A CNN não consegue, de forma consistente, separar a textura da calça do padrão da camisola, poluindo o tensor discriminativo mal a imagem transite de uma peça 2D plana para um contexto de rua.

2. **Custos de Pipeline em Cascata:** A alternativa técnica para contornar o colapso dos atributos obrigaria à implementação de dezenas de redes fechadas em cascata (uma ResNet para Categoria, outra para Cor, outra para Padrão). Tal abordagem multiplicaria a latência e o consumo de memória VRAM, inviabilizando qualquer resposta ágil em sistemas REST API.

Conclui-se, assim, que o esforço computacional e arquitetural necessário para escalar redes convolucionais discriminativas à realidade multiatributo industrial é ineficiente e obsoleto, validando a transição do nosso projeto para a versatilidade das arquiteturas fundacionais.

5 Arquitetura da Solução Base: Pipeline Multimodal (Fashion-CLIP)

O núcleo de extração de metadados do **DeepFashion AI** baseia-se num pipeline de inferência multimodal avançado, instanciado no módulo `predictor.py`. A arquitetura selecionada recaiu sobre o modelo `patrickjohncyh/fashion-clip` [3], uma variante do CLIP da OpenAI submetida a um processo de **fine-tuning** específico para o domínio do vestuário e da moda.

5.1 Engenharia de Prompts e Construção de Text Banks (Ensemble)

Ao contrário das abordagens de classificação **one-hot encoded** tradicionais, o CLIP requer que as classes sejam representadas como descrições em linguagem natural. Para mitigar o problema da ambiguidade semântica e da sensibilidade do modelo a pequenas variações textuais (conhecido como **prompt fragility**), implementámos uma técnica de **Ensemble de Prompts**.

Em vez de utilizar uma descrição única por categoria, o sistema pré-computa um **Text Bank** combinando a classe desejada com múltiplas matrizes textuais (e.g., "a photo of a {}", "a fashion photo of a {}", "a studio photo of a {}"). Para atributos complexos, a nossa arquitetura utiliza **templates** especializados consoante a tipologia do metadado:

- **Padrões (Type 1):** "clothing with {} pattern" ou "a {} print fabric".
- **Texturas (Type 2):** "a {} fabric garment" ou "clothing with {} texture".
- **Silhuetas (Type 3):** "a {} style clothing".

Matematicamente, para um determinado atributo A , o modelo gera o **embedding** textual para cada variante do **prompt**, $E_1, E_2, \dots, E_n$. O **embedding** final da classe E_A resulta da normalização L2 da média vetorial desses **prompts**:

$$E_A = \frac{\sum_{i=1}^n E_i}{\left\| \sum_{i=1}^n E_i \right\|}$$

Esta pré-computação ocorre na fase de inicialização do servidor (Flask [4]), garantindo que a inferência em tempo real apenas exige o processamento da imagem, reduzindo drasticamente a latência da API.

5.2 Test-Time Augmentation (TTA)

Imagens reais captadas em contexto de e-commerce apresentam fortes variações de iluminação e pose. Para dotar o sistema de resiliência face a estes artefactos, o **DeepFashion AI** integra uma rotina de TTA (**Test-Time Augmentation**).

O TTA opera gerando múltiplas **views** da mesma imagem durante o momento da inferência, sem necessidade de alterar os pesos do modelo. No nosso pipeline, a imagem de entrada passa pelas seguintes transformações sequenciais:

1. **Base:** Redimensionamento para 224x224 (Bicubic Interpolation), Center Crop e Normalização estatística padrão do CLIP.
2. **Flip:** Aplicação de `RandomHorizontalFlip(p=1.0)`.
3. **Jitter:** Aplicação de `ColorJitter` com variações estocásticas de brilho (20%), contraste (20%), saturação (20%) e matiz (5%).

Os tensores de píxeis de todas as views são passados simultaneamente pelo **Vision Transformer (ViT)** [10] do CLIP. Tal como no **Text Bank**, o **embedding** visual final é obtido através da concatenação, cálculo da média ao longo da dimensão das views e subsequente normalização L2. Esta estratégia garante que a extração de texturas complexas (como camuflado ou xadrez) não seja afetada por reflexos locais de luz.

5.3 Análise do Benchmark TTA (Trade-off de Desempenho)

Para avaliar matematicamente a viabilidade operacional desta técnica, o grupo desenvolveu um script de testes dedicado (`benchmark_tta.ipynb`). A análise rigorosa dos dados empíricos gerados alterou substancialmente a perspetiva teórica sobre a utilidade desta abordagem no nosso pipeline.

1. Impacto na Exatidão (Ganhos Marginais): Conforme ilustrado na Figura 2, a ativação do TTA resulta efetivamente num aumento da precisão global. No entanto, este ganho empírico revelou-se estatisticamente insignificante no contexto de produção. As variações visuais estocásticas geradas pelas múltiplas **views** corrigem oclusões e falsos positivos muito pontuais, mas não elevam o patamar de eficácia da rede de forma que justifique uma alteração sistémica.

Esta ausência de melhoria expressiva explica-se pela própria arquitetura dos Modelos Fundacionais (como o CLIP): uma vez que foram pré-treinados em escalas massivas de dados com recurso a **data augmentation** nativo agressivo, os seus **embeddings** já são inerentemente robustos e invariantes a pequenas translações, espelhamentos ou alterações cromáticas. Consequentemente, o TTA na fase de inferência não introduz qualquer nova vantagem semântica que o modelo já não consiga generalizar por defeito.




Figura 1. Impacto do Test-Time Augmentation (TTA) na Accuracy. A comparação métrica revela que a utilização do TTA resulta em ganhos de precisão estatisticamente marginais (inferiores a 2%) tanto no Top-1 como no Top-5 para todas as variantes do modelo CLIP testadas.

2. Penalização na Latência (Custo Operacional Elevado): Em contrapartida, a observação da Figura 3 demonstra que o custo computacional do TTA é inoportuno para integrações em tempo real. Uma vez que o motor de inferência é obrigado a realizar múltiplos **forward passes** no **Vision Transformer** para processar as imagens geradas, o tempo médio de resposta sofre uma degradação crítica, aumentando para praticamente o dobro da latência base.




Figura 2. Impacto do TTA na Latência de Inferência (escala logarítmica). A ativação do TTA penaliza severamente o tempo de resposta do sistema, multiplicando o custo computacional entre 1.8x a 2.8x face à inferência base (No-TTA), o que compromete o processamento em tempo real.

3. Veredicto da Análise de Trade-off: O cruzamento destas duas métricas (consolidado no gráfico de dispersão abaixo) evidencia um ROI (Retorno sobre o Investimento) computacional puramente negativo.




Figura 3. Análise Global de Trade-off (Accuracy vs. Latência). O gráfico de dispersão demonstra graficamente um Retorno sobre o Investimento (ROI) negativo: o ligeiro deslocamento vertical (ganho pontual na precisão) não compensa o drástico deslocamento horizontal (aumento acentuado dos milissegundos exigidos por imagem).

Conclui-se taxativamente que o ligeiro incremento na robustez visual não justifica o estrangulamento de uma **framework** pensada para o **e-commerce** ágil. Por esta razão, o grupo de trabalho determina que o uso do TTA é inviável como fluxo de ingestão padrão. Esta descoberta suporta a nossa decisão de desenvolvimento na Interface Web, onde o TTA não é uma imposição arquitetural, mas sim um mero interruptor dinâmico de carácter exploratório, mantido inativo por defeito para preservar a resposta instantânea da API.

6 A Fronteira dos LLMs Multimodais: Integração LLaVA

No limite do Estado da Arte, a Visão Computacional fundiu-se com o Processamento de Linguagem Natural, dando origem aos **MLLMs** (Grandes Modelos de Linguagem Multimodais). Para avaliar o potencial desta fronteira tecnológica, o **DeepFashion AI** integra de forma nativa uma rota de inferência suportada pelo modelo **LLaVA** (Large Language-and-Vision Assistant).

6.1 Arquitetura de Integração e Wrapper Local (Ollama)

Para garantir a privacidade dos dados optamos por não depender de APIs externas (como a da OpenAI). Implementamos o modelo localmente recorrendo ao motor **Ollama**. Através da configuração de um **Modelfile** customizado, instanciamos a versão especializada **deepfashion-llava**.

A ligação entre a interface Web em Flask e o motor local foi encapsulada no módulo **ollama_predictor.py**. Para evitar o **overhead** de gravação de imagens temporárias complexas, o sistema codifica a imagem recebida numa **string** Base64 (**encode_image**) e envia-a no **payload** de um pedido HTTP POST para o endpoint REST da API do Ollama (<http://localhost:11434/api/generate>).

Conforme documentado no nosso **benchmark** empírico, a execução local destes tensores generativos impõe uma latência elevada (média de 6317 milissegundos por imagem), justificando o posicionamento estrutural do LLaVA como um sistema de **fallback** para curadoria complexa, e não como a rota primária de ingestão.

6.2 Prompting Visual e Normalização de Schema

No paradigma do LLaVA, a extração de **features** não decorre do cálculo de distância de cossenos entre vetores (como no CLIP), mas sim de um processo generativo instruído. O modelo recebe a imagem acompanhada do **prompt** estrito: **“Analyze this clothing image and output only JSON.”**

O maior desafio operacional da Inteligência Artificial Generativa reside na formatação estruturada. Uma vez que o LLM pode variar semanticamente as chaves do JSON (por exemplo, usar a chave **"color"** em vez de **"name"**), o nosso **wrapper** inclui uma rotina robusta de normalização. O script intercepta a resposta crua, itera sobre os **arrays** de **colors** e **attributes** (limitando aos Top 5 e Top 10, respetivamente), forçando o mapeamento exato para a taxonomia exigida pelo **frontend**. Adicionalmente, caso o modelo não retorne os valores em formato de **top_k**, o sistema reconstrói o objeto inferindo a classe principal com uma taxa de confiança padronizada (0.85), assegurando assim a estabilidade ininterrupta da aplicação Web.

6.3 Trade-offs: Flexibilidade vs. Latência

Esta exploração provou que o LLaVA oferece uma grande flexibilidade, permitindo “conversar” com a peça de roupa e extrair atributos complexos que não estejam pré-mapeados num **Text Bank**. No entanto, o nosso **benchmark** empírico identificou os seguintes constrangimentos operacionais:

- **Latência Generativa:** O tempo necessário para o modelo gerar **tokens** sequenciais (**Time-to-First-Token** e **Tokens-per-Second**) torna o processamento visivelmente mais lento do que a inferência do **Fashion-CLIP**, que ocorre numa única passagem vetorial (**forward pass**). O nosso script impõe mesmo um **timeout** de 120 segundos nas chamadas à API local para precaver bloqueios na rede.

- **O Paradoxo da Exatidão (Penalização Lexical):** Embora o LLaVA possua uma capacidade semântica avançada, o nosso **benchmark** quantitativo registou uma exatidão residual (22%). Isto não reflete uma falha visual, mas sim a ausência de um mapeamento estrito para o vocabulário rígido do **dataset** original. Ao gerar descrições livres, o modelo falha a métrica matemática de **Exact Match**, penalizando a sua avaliação exata.
- **Custo de Hardware:** O carregamento das matrizes do LLM (mesmo com quantização no Ollama) exige elevada disponibilidade de memória VRAM, limitando o processamento paralelo em servidores mais modestos.

7 Metodologia de Avaliação e Benchmark de Modelos

Para validar as escolhas arquiteturais do **DeepFashion AI** e fornecer ao CITEVE dados concretos de viabilidade operacional, o grupo estabeleceu um referencial de avaliação (**benchmark**) tripartido. Este **benchmark** compara as três frentes tecnológicas desenvolvidas: a CNN (Discriminativo Tradicional), o Fashion-CLIP (Multimodal Contrastivo) e o LLaVA (Multimodal Generativo).

7.1 Métricas de Avaliação

Para garantir uma análise holística, o nosso **benchmark** foi estruturado em torno das seguintes métricas, que cruzam a performance matemática com os requisitos operacionais vitais para a implementação em **datacenters** ou instâncias **cloud**:

1. **Accuracy Top-1 e Top-5 (Categoria):** A precisão estatística na identificação da taxonomia principal da peça, aferindo o acerto direto (Top-1) e a presença da classe real entre as cinco predições com maior margem de confiança (Top-5).
2. **Expressividade da Tarefa:** A capacidade arquitetural de classificar múltiplos atributos visuais em simultâneo (Cor, Padrão e Silhueta).
3. **Latência de Inferência:** O tempo de resposta processual (**Time-to-Response**) exigido por cada imagem.
4. **Custo Computacional:** O volume de recursos de **hardware** (VRAM) exigido para a alocação dos tensores na memória gráfica.

7.2 Análise Quantitativa e Resultados do Benchmark

Para consubstanciar a avaliação empírica de forma quantitativa, o grupo desenvolveu um script de testes automatizado (**benchmark.ipynb**). Este script submeteu os diferentes motores de inferência ao **Test Set** oficial do **dataset** DeepFashion, extraíndo métricas diretas de exatidão topológica (Categoria da Peça) e medindo a latência real de processamento.

Os resultados obtidos encontram-se sintetizados na Figura 5 e na Tabela 1.




Figura 4. Benchmark Comparativo Global. À esquerda: Exatidão Top-1 e Top-5 estrita à Categoria, evidenciando o domínio topológico da rede focada (ResNet-50) e a estabilidade do Fashion-CLIP. À direita: O abismo latencial entre as arquiteturas vetoriais instantâneas (escala dos milissegundos) e o motor generativo LLaVA (escala dos 6.3 segundos).

Para uma leitura justa e rigorosa dos valores absolutos que compõem o gráfico anterior, é fundamental ressaltar as condições metodológicas utilizadas. Este ensaio quantitativo avaliou estritamente a capacidade matemática de prever a **Categoria** (tipo de silhueta) do vestuário, isolando-a dos restantes atributos. Neste contexto, a métrica de **Top-1** indica a percentagem de vezes em que a primeira previsão do modelo correspondeu à etiqueta exata, enquanto o **Top-5** indica a frequência com que a etiqueta real figurava algures entre as cinco previsões com maior grau de confiança. Os dados numéricos brutos resultantes desta extração estão detalhados na tabela seguinte.

Tabela 4. Benchmark Quantitativo: Predição de Categoria Isolada no Test Set do DeepFashion.

Modelo Testado	Exatidão (Top-1)	Exatidão (Top-5)	Latência Média (ms)
CNN (ResNet50)	68.00%	93.20%	4.1 ms
Fashion-CLIP	43.80%	87.00%	21.7 ms
LLaVA (Ollama)	22.00%	22.00%	6317.0 ms

A leitura isolada destes dados brutos exige uma interpretação crítica face ao domínio do problema (Extração Multi-Atributo):

1. O Paradoxo da CNN: A ResNet50 atinge uma performance de excelência na identificação topológica pura (68.00% de Top-1 e 93.20% de Top-5), benefi-

ciando da sua velocidade extrema de 4.1 milissegundos. Contudo, esta vitória quantitativa é ilusória no contexto multi-atributo. Esta rede dedicou 100% da sua capacidade de processamento geométrico para prever **apenas** a silhueta da peça. Se lhe fosse exigido prever simultaneamente a cor e a textura (**Multi-Task Learning**), esta métrica colapsaria (como aferido nos nossos testes exploratórios que registaram métricas de **Exact Match** global na ordem dos 10%), confirmando o estrangulamento operacional dos modelos **Closed-Set**.

2. A Superioridade Operacional do Fashion-CLIP: Apesar de registar um Top-1 inferior à CNN dedicada, o Fashion-CLIP regista um Top-5 consistente de 87.00%. Isto significa que, em 87% das inferências, a categoria correta encontra-se no espetro de previsão da API, com um tempo de resposta de apenas 21.7 milissegundos. O verdadeiro triunfo desta arquitetura reside no facto de que, **nestes mesmos 21.7 milissegundos**, o modelo consegue prever não só a categoria, mas extrair também os padrões e os tons cromáticos através dos matrizes textuais dinâmicas, algo que a CNN é incapaz de fazer.

3. A Penalização Semântica do LLaVA (Fronteira Generativa): A exatidão matemática do LLaVA fixou-se nuns residuais 22.00%. Este valor não traduz uma incapacidade visual do modelo, mas expõe as falhas da métrica de **Exact Match** em algoritmos generativos de texto livre. Por exemplo, perante uma etiqueta de validação estrita como “Blouse”, o LLaVA frequentemente gera sinónimos semanticamente corretos (ex: “Women’s Shirt”), que o **script** de avaliação contabiliza forçosamente como erro (0%). O verdadeiro fator de rejeição para a adoção desta tecnologia como **pipeline** de ingestão primário reside no seu custo temporal: **6.3 segundos** exigidos por imagem, tornando a sua adoção proibitiva para o processamento em tempo real de grandes volumes de catálogos.

8 Estudo Experimental: Avaliação em Cenários de Complexidade Visual

Para consubstanciar a nossa pesquisa académica e estabelecer um **benchmark** prático entre os modelos documentados (CNN, Fashion-CLIP e LLaVA), delineámos uma metodologia empírica baseada em testes visuais de complexidade crescente. O objetivo é aferir o comportamento e a robustez arquitetural face ao ruído de fundo e à sobreposição semântica.

8.1 Definição dos Cenários de Teste

A experimentação foi conduzida mediante três contextos fotográficos de complexidade crescente, representativos da cadeia de valor da indústria têxtil (desde o ambiente de estúdio até ao **user-generated content** na via pública):

- 1. Cenário 1 (Fotografia 2D / Peça Plana):** A peça de vestuário encontra-se isolada num fundo neutro (e.g., deitada, ou num cabide de estúdio). Representa o ambiente laboratorial ideal, isento de oclusões, reflexos não controlados ou interferência anatômica.

2. **Cenário 2 (Modelo Único):** A peça encontra-se vestida por uma única pessoa. Este cenário introduz o problema do “ruído antropomórfico”, o algoritmo necessita de distinguir o tecido da pele humana, contornar dobras do tecido induzidas pela pose, e isolar a peça principal face a acessórios ou partes secundárias.
3. **Cenário 3 (Fotografia Multi-Indivíduo):** Imagem com múltiplas pessoas a usar peças distintas em simultâneo. É o teste de **stress** absoluto para aferir a ocorrência de **Context Blending** (fundir o padrão de uma pessoa com a cor de outra).

8.2 Ensaios Visuais e Extração de Atributos

Abaixo encontram-se documentados os resultados diretos da inferência para as três imagens de teste submetidas ao pipeline.

Cenário 1: Ambiente Controlado (2D)

Este cenário atua como o caso de controlo estéril. Tratando-se de uma peça isolada em ambiente neutro e com iluminação uniforme, a expectativa teórica é de um desempenho ótimo generalizado. A ausência de elementos anatómicos ou de cenários de fundo permite avaliar a capacidade primária de cada rede em mapear a taxonomia estrita da peça sem a interferência de ruído externo.



Figura 5. Imagem de Teste - Cenário 1.

Modelo	Categoria	Cor	Atributos
CNN(Res-Net-50)	<u>Shorts</u> (Joggers/Jacket/ Parka)	N/A	N/A
Fashion-CLIP	<u>Shorts</u> (Cutoffs/Capris/ Sweatshorts)	Olive (Green/Brown/ Beige)	cargo/camo/ca- mouflage/capri
LLaVA	<u>Cargo Pants</u> (Shorts/Jeans/ Joggers)	Camouflage (Black/White/ Red)	Camouflage Pat- tern/Pocket style/ Waistband design

Cenário 2: Modelo Único

A introdução da figura humana eleva drasticamente a complexidade da inferência. Neste cenário, os tensores do modelo necessitam de executar uma segregação semântica implícita: ignorar a coloração da pele do modelo, as sombras, e focar apenas na peça de roupa. É o cenário típico de **e-commerce**, desenhado para testar a resiliência dos **Text Banks** do CLIP e o foco da CNN face ao ruído antropomórfico.



Figura 6. Imagem de Teste - Cenário 2.

Modelo	Categoria	Cor	Atributos
CNN(Res-Net-50)	<u>Sweater</u> (Tee/Top/Hoodie)	N/A	N/A
Fashion-CLIP	<u>Top</u> (Sweater/Blouse/Jersey)	<u>Grey</u> (Navy/Purple/Blue)	pullover/mineral wash/french terry/bleached
LLaVA	<u>Blouse</u> (Button-Down/Sweater/Jersey)	<u>Black</u> (White/Red/Blue)	Sleeve length, Neckline, Fit

Cenário 3: Ruído Visual (Várias pessoas / Contexto Real)

O derradeiro ensaio simula o contexto real. A presença de múltiplos indivíduos, sobreposição de roupas e forte poluição visual no fundo da fotografia força o limite das arquiteturas de processamento global. Este teste empírico foi concebido expressamente para forçar o erro e detetar o fenómeno de **Context Blending**, validando visualmente a necessidade da arquitetura de **Smart Cropping** (YOLO) delineada no trabalho futuro deste relatório.



Figura 7. Imagem de Teste - Cenário 3.

Modelo	Categoria	Cor	Padrão/Textura
CNN(Res-Net-50)	<u>Jeans</u> (Flannel/Blouse/Tee)	N/A	N/A
Fashion-CLIP	<u>Jeggings</u> (Flannel/Jeans/Blouse)	<u>Grey</u> (Blue/Navy/Brown)	plaid shirt/chambray/classic skinny/checked
LLaVA	<u>Blouse</u> (Button-Down/Tank/Sweater)	<u>Black</u> (White/Red/Blue)	Sleeve length/Neckline/Fit/Sleeve style

8.3 Veredicto do Estudo Empírico

A análise qualitativa das predições corrobora integralmente as métricas do **benchmark** quantitativo, expondo de forma visual e inquestionável as forças e as limitações estruturais de cada arquitetura:

1. **A Estreiteza da CNN (ResNet-50):** O modelo provou ser robusto na identificação topológica primária (acertando na silhueta dos **Shorts** e do **Sweater**), mas confirmou a sua inaptidão para fluxos de **e-commerce**. Por ser uma rede discriminativa focada na categoria, é totalmente “cega” a cores e padrões (N/A), obrigando à implementação de dispendiosas redes em cascata caso se pretendesse extrair a matriz completa.
2. **A Excelência e o Calcanhar de Aquiles do Fashion-CLIP:** Nos Cenários 1 e 2, o Fashion-CLIP revelou-se consistente e demonstrou o verdadeiro poder do **Zero-Shot Learning**. Conseguiu extrair com precisão cirúrgica texturas e cores complexas (identificando perfeitamente o “**camo**” / “**olive**” no primeiro teste e o tecido “**french terry**” no segundo). Contudo, o Cenário 3 expôs exatamente a sua vulnerabilidade arquitetural: o **Context Blending**. Ao processar a fotografia de grupo de forma global, os tensores de atenção da rede fundiram-se, gerando um resultado caótico que cruza a cor de uma modelo (**Grey** das calças) com o padrão de outra (**plaid shirt** / camisa axadrezada).
3. **A Desilusão Generativa (LLaVA):** Apesar de ser a fronteira do Estado da Arte, o LLaVA falhou substancialmente neste formato de extração direta (**zero-shot** sem **prompting** iterativo). O modelo demonstrou uma forte propensão para alucinações morfológicas e cromáticas, por exemplo, classificou repetidamente as peças como “**Button-Down**” (camisas com botões) em camisolas totalmente lisas (Cenário 2) e forçou a presença da cor **Black** onde esta não era de todo a dominante. Adicionalmente, no campo dos atributos, limitou-se a devolver os nomes das chaves genéricas (e.g., “**Sleeve length**”, “**Neckline**”) em vez de extrair os respetivos valores visuais da imagem.

Conclusão da Prova de Conceito: Fica empiricamente provado que o Fashion-CLIP atua como o motor de inferência mais equilibrado e capaz para

o **DeepFashion AI**. Enquanto a arquitetura discriminativa (CNN) demonstra precisão na silhueta mas é “cega” à extração conjunta dos restantes atributos, e a fronteira generativa (LLaVA) se revela inconstante e propensa a alucinações visuais, o Fashion-CLIP assume-se como o compromisso ideal, o “meio-termo” perfeito que garante consistência multiatributo com latência em tempo real. No entanto, a falha documentada no Cenário 3 dita que, para a plataforma processar fotografias de rua com múltiplas pessoas em segurança, é obrigatório implementar um sistema de purga espacial prévia, justificando a arquitetura algorítmica de recorte referida no capítulo seguinte.

9 Proposta de Arquitetura Futura: Pipeline de Smart Cropping Dinâmico

A validação conduzida no nosso estudo experimental expôs duas vulnerabilidades arquiteturais que limitam a transição do **DeepFashion AI** de uma prova de conceito laboratorial para um sistema de produção industrial plenamente autónomo. Em primeiro lugar, o fenómeno de **Context Blending** a fusão semântica de atributos entre peças distintas quando o motor CLIP processa imagens com múltiplos artigos ou fundos ruidosos. Em segundo lugar, a incapacidade do atual **pipeline** monolítico de capitalizar as forças complementares de cada paradigma de IA a precisão supervisionada das CNNs, a flexibilidade **zero-shot** do CLIP e a capacidade de raciocínio generativo dos MLLMs.

Para superar estas limitações, o grupo propõe uma arquitetura evolutiva de quatro estágios, orquestrados em cascata sequencial. Esta **pipeline** decompõe o problema da catalogação têxtil nas suas dimensões ontológicas fundamentais localização, classificação taxonómica, extração multi-atributo e sumarização descritiva atribuindo a cada dimensão o motor de inferência que maximiza a relação entre exatidão e latência. A arquitetura proposta obedece ao seguinte fluxo de processamento:




Figura 8. Arquitetura Proposta

9.1 Localização e Recorte (YOLO)

Um detetor YOLO atuaria como localizador espacial não como classificador treinado com as anotações de bounding box já disponíveis no dataset (list_bbox.txt, list_landmarks.txt) mas ainda não exploradas no projeto. Ao detetar as coordenadas de cada peça antes de qualquer cálculo vetorial, resolve-se na origem o Context Blending do Cenário 3, em vez de depender da atenção do CLIP para ignorar outros indivíduos. As coordenadas seriam expandidas em 5–10% (padding) para não amputar detalhes morfológicos relevantes (bainhas, punhos), com a área exterior ao recorte mascarada como fundo neutro.

9.2 Classificação da Categoria (ResNet)

O patch isolado permite reintroduzir a ResNet-50, confinada exclusivamente à categoria tarefa em que atingiu 68,00% Top-1 a 4,1 ms. O motivo por que esta vantagem não foi usada na arquitetura original é o colapso Multi-Task quando a rede é forçada a prever também cor/padrão. Ao limitar a CNN a um único cabeçalho sobre um recorte já livre de ruído e de outros indivíduos, eliminam-se as duas causas dessa degradação, sem recorrer a múltiplas redes algo que consideramos inviável.

9.3 Atributos e Banco de Tendências (Fashion-CLIP)

Uma vez isolado espacialmente e classificado por categoria, o recorte dinâmico transita para o motor do Fashion-CLIP. Nesta fase, mantém-se ativa a otimização através de Text Banks (Ensemble de Prompts) para a predição da restante taxonomia detalhada. Conforme atestado empiricamente nos Cenários 1 e 2, a eficácia deste modelo na extração de atributos complexos (como cor e textura) atinge o seu pico de precisão quando a peça se encontra perfeitamente segregada do ambiente envolvente.

9.4 Geração de Descrição (LLaVA)

As falhas do LLaVA foram a alucinação e campos vazios resultam de lhe pedir para extrair factos visuais, tarefa em que o benchmark já o desqualificou. Propõe-se reposicioná-lo como gerador de texto fundamentado: recebe a categoria e os atributos já validados pelas fases anteriores e produz apenas uma descrição fluente de catálogo, em vez de decidir categoria/cor. Isto elimina por construção ambos os padrões de falha e permite correr o LLaVA de forma assíncrona, fora do caminho crítico de extração.

10 Implementação da Prova de Conceito (Interface Web)

A componente teórica e o treino de modelos carecem de utilidade prática sem um veículo de acesso e demonstração. Para materializar o motor analítico, o grupo desenvolveu uma **PoC** (Prova de Conceito) interativa consubstanciada

numa Aplicação Web. Esta camada de **frontend** e API REST foi integralmente programada recorrendo à **framework** Flask para Python (`app.py`).

10.1 Arquitetura Assíncrona e Segurança (Cliente-Servidor)

A infraestrutura do servidor atua de forma dual: processa os motores de inferência em Python e disponibiliza o **endpoint** `/predict`, capaz de ser consumido pela própria interface ou por sistemas externos.

Para salvaguardar a estabilidade do servidor em ambiente de demonstração, o módulo de receção implementa salvaguardas estritas:

- **Validação de Ficheiros:** O **upload** restringe extensões e utiliza a função `secure_filename()` acoplada a **timestamps** ISO (e.g., `20260603_143000_image.jpg`). Isto previne vulnerabilidades de execução remota (**Path Traversal**) e sobreposição acidental de ficheiros em disco.
- **Limitação de Carga:** O tamanho máximo do **payload** foi capado em 16 MB (`MAX_CONTENT_LENGTH`), protegendo a memória do servidor contra exaustão (mitigando potenciais ataques **Denial-of-Service**).

No lado do cliente, a orquestração visual é gerida pelo script `main.js`. Utilizando chamadas assíncronas (**Fetch API**), a aplicação processa submissões via **drag-and-drop** sem necessitar de recarregar a página, emulando o comportamento de uma **Single Page Application** (SPA). Este script interceta o estado dos seletores gráficos e empacota a imagem num **payload** `multipart/form-data`, garantindo uma comunicação fluida e não bloqueante com o **backend**.

10.2 Injeção Dinâmica de Modelos e Hiperparâmetros

O maior trunfo tecnológico da nossa aplicação Web é a sua natureza arquiteturalmente agnóstica. Em vez de acoplar o **frontend** rigidamente a um único modelo, desenvolvemos um seletor dinâmico que reconstrói o pipeline de inferência a cada pedido, otimizando a alocação de memória.

A interface exibe um catálogo alimentado pelo dicionário `AVAILABLE_MODELS`, permitindo ao utilizador alternar em tempo real entre:

- **Fashion-CLIP** (O modelo SOTA recomendado);
- Múltiplas variantes fundacionais do CLIP da OpenAI (e.g., `clip-vit-large-patch14`);
- **LLaVA** (A fronteira generativa local gerida via Ollama);
- **CNN Baseline** (A arquitetura ResNet-50 para avaliação de controlo).

Adicionalmente, através de um interruptor booleano (`no_tta`), o utilizador pode forçar a ativação ou desativação da rotina de **Test-Time Augmentation** no motor `predictor.py`. Esta funcionalidade interativa permite observar em tempo real o **trade-off** fundamentado no nosso estudo empírico: o ganho residual na robustez da inferência face à penalização na latência.

10.3 Normalização e Estruturação do Output (JSON)

Independentemente de a inferência transitar pelo Fashion-CLIP, pelo LLaVA ou pela CNN, a **backend** Flask implementa uma interface contratual que obriga todos os métodos a devolverem um schema padronizado.

O resultado do processamento é devolvido ao **frontend** na forma de uma estrutura JSON rigorosa contendo:

- **macro_category**: Decisão do classificador híbrido;
- **category**: Top-K silhuetas;
- **attributes**: Vetor de Top 10 texturas/padrões ranqueados por confiança;
- **colors**: Vetor de Top 5 tons dominantes.

Para simular o contexto de Big Data de retalho de moda, o nosso **app.py** foi programado para, em paralelo ao retorno via HTTP 200, guardar uma cópia física do JSON, associando os metadados extraídos diretamente à imagem local, garantindo a rastreabilidade persistente dos resultados gerados.

11 Considerações Finais e Gestão do Projeto

11.1 Considerações Éticas, Legais e Económicas

A implementação de sistemas de Inteligência Artificial na indústria retalhista levanta questões multidimensionais que devem ser salvaguardadas na transição de uma **PoC** (Prova de Conceito) para um ambiente de produção.

Dimensão Ética e Viés de Dados (Bias) A principal preocupação ética em modelos de visão treinados com dados massivos da Internet (como o CLIP) e datasets como o **DeepFashion** é o viés representacional. Estas arquiteturas tendem a sobreajustar-se (**overfit**) a peças de vestuário ocidentais e fotografadas em modelos humanos com biótipos ou tons de pele sobre-representados nos dados de treino. Embora a nossa proposta teórica de **Smart Cropping** mitigue este fator ao isolar apenas a peça de roupa, é imperativo garantir que o sistema não discrimina peças de vestuário culturalmente específicas.

Dimensão Legal e Direitos de Autor No contexto legal, a catalogação automática levanta a questão dos Direitos de Autor (**Copyright**) e da Privacidade. O processamento de **User-Generated Content** exige conformidade com o **RGPD**, especialmente face ao tratamento inadvertido de rostos ou outros identificadores biométricos. O nosso pipeline minimiza este risco ao não reter as imagens de entrada na base de dados após a extração dos metadados (JSON).

Dimensão Económica Do ponto de vista económico, a automação do **tagging** representa uma redução drástica nos custos operacionais do CITEVE e dos

seus parceiros. Contudo, como demonstrado no nosso **benchmark**, a adoção da fronteira SOTA (LLaVA) acarreta custos elevados de infraestrutura (**cloud computing** com GPUs dedicadas). A nossa solução mitiga este impacto económico ao definir o **Fashion-CLIP** (mais leve e rápido) como o modelo padrão, reservando as arquiteturas mais pesadas apenas para cenários de ambiguidade que necessitem de análise profunda.

11.2 Gestão do Projeto (Metodologia SCRUM)

Para assegurar uma entrega contínua e alinhada com os requisitos de engenharia, o desenvolvimento foi orquestrado sob a metodologia **SCRUM**, adaptada à dimensão estrutural da equipa. O ciclo de vida do projeto foi dividido em **Sprints** iterativos:

- **Sprint 1 (Planeamento e Fundações de Dados):** Foco na investigação do Estado da Arte, definição do **Product Backlog**, aquisição, validação e purga de dados corrompidos do **dataset** (módulo `dataset_manager.py`).
- **Sprint 2 (Prova de Conceito e Arquitetura Base):** Implementação do núcleo funcional. Desenvolvimento do motor multitarefa contrastivo (Fashion-CLIP), normalização contratual dos schemas JSON e construção da arquitetura Cliente-Servidor assíncrona em Flask.
- **Sprint 3 (Estudo Empírico e Documentação):** Fase dedicada à investigação laboratorial comparativa, contemplando a avaliação da **Baseline** Convolutiva (ResNet-50), o encapsulamento local da fronteira generativa (LLaVA via Ollama) para cenários extremos, e a consolidação analítica do presente relatório técnico.

O planeamento cronológico detalhado, a decomposição de **User Stories** e a gestão de tarefas encontram-se documentados no ficheiro anexo **Backlog_PIA.docx**, fechando assim o ciclo de desenvolvimento iterativo deste projeto.

11.3 Declaração de Utilização de Ferramentas de Inteligência Artificial

Em conformidade com as diretrizes da Unidade Curricular de Projeto de Inteligência Artificial, o Grupo 6 declara a utilização de ferramentas baseadas em LLMs como apoio ao desenvolvimento deste trabalho.

As ferramentas foram utilizadas nos seguintes moldes:

1. **Apoio à Programação:** Utilização de assistentes de código para otimização de rotinas em Python (nomeadamente a construção de expressões regulares no script `recover_labels.py` e refatorização de funções na API Flask).
2. **Apoio à Redação e Estruturação:** Utilização de IA generativa para auxiliar na organização lógica do relatório técnico e na revisão linguística do mesmo, garantindo a clareza e o rigor do jargão técnico e científico.

12 Conclusão

A jornada de investigação e desenvolvimento do **DeepFashion AI** cumpriu integralmente os objetivos estipulados no **backlog** do projeto. Este trabalho consolidou-se como um estudo do Estado da Arte e uma validação científica das fronteiras tecnológicas da Visão Computacional. A plataforma desenvolvida serve como uma Prova de Conceito (PoC) laboratorial e exploratória, demonstrando empiricamente os limites operacionais, vantagens e constrangimentos que o CITEVE e o tecido industrial têxtil devem ponderar ao avaliar a transição de processos de catalogação manuais para sistemas inteligentes baseados em IA.

A principal conclusão deste projeto é a eleição do **Fashion-CLIP** como a arquitetura “vencedora” e recomendada para implementação nos fluxos de produção. O nosso **benchmark** empírico validou que esta solução multimodal contrastiva suplanta os **pipelines** discriminativos tradicionais (CNNs) no tratamento de metadados complexos, oferecendo o melhor compromisso (**trade-off**) entre a elevada exatidão multiatributo e uma latência de operação instantânea (21.7 ms), o que inviabiliza o uso da CNN para contextos dinâmicos e do LLaVA para processamento ágil. Ao contornar a necessidade de **datasets** massivamente anotados e ao evitar a rigidez das **Loss Functions** de múltiplas cabeças, o paradigma **Zero-Shot** garante a longevidade do **software**. A plataforma permite a introdução de novas categorias ou padrões sazonais apenas através da atualização do dicionário semântico, sem exigir o retreino estrutural da rede.

O desenvolvimento exigiu a superação de constrangimentos reais de **Data Engineering**, destacando-se a resolução de corrupções estruturais no repositório de origem (limpeza algorítmica de HTML e deduplicação MD5). Adicionalmente, a resiliência do sistema foi cimentada pela mitigação da fragilidade textual através de **Text Banks (Ensemble de Prompts)** e por uma análise crítica profunda a técnicas de **Test-Time Augmentation (TTA)** — que, tendo provado empiricamente um retorno computacional negativo para ambientes **real-time**, foi relegado para um interruptor de exploração avançada na interface Web.

Em suma, o **DeepFashion AI** demonstra que a convergência entre modelos fundacionais e arquiteturas Web agnósticas estabelece a nova base arquitetural para a automação na moda, substituindo milhares de horas de curadoria manual por processos determinísticos, auditáveis e de elevada precisão.

References

- [1] Z. Liu, P. Luo, S. Qiu, X. Wang, and X. Tang, “DeepFashion: Powering Robust Clothes Recognition and Retrieval With Rich Annotations,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 1092–1101. [Online]. Available: https://openaccess.thecvf.com/content_cvpr_2016/papers/Liu_DeepFashion_Powering_Robust_CVPR_2016_paper.pdf
- [2] F. Ghadiri, “Cloth Category Classifier using DeepFashion dataset.” [Online]. Available: https://github.com/FarnooshGhadiri/Cloth_category_classifier

- [3] P. J. Chia, G. Attanasio, F. Pelosin, C. Espinosa-Zaragoza, A. Pelegrin, and M. Ciaramita, “Fashion-CLIP: Customizing Vision-Language Models for the Fashion Domain,” in *Computer Vision – ECCV 2022 Workshops*, Springer, 2022, pp. 287–304. [Online]. Available: <https://github.com/patrickjohncyh/fashion-clip>
- [4] M. Grinberg, *Flask Web Development: Developing Web Applications with Python*, 2nd ed. O'Reilly Media, Inc., 2018. [Online]. Available: <https://flask.palletsprojects.com/>
- [5] Ollama Team, “Ollama: Get up and running with large language models locally.” [Online]. Available: <https://ollama.com/>
- [6] H. Liu, C. Li, Q. Wu, and Y. J. Lee, “Visual Instruction Tuning,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. [Online]. Available: <https://arxiv.org/abs/2304.08485>
- [7] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778. [Online]. Available: <https://arxiv.org/abs/1512.03385>
- [8] Q. Dong, S. Gong, and X. Zhu, “Multi-task curriculum transfer deep learning of clothing attributes,” in *2017 IEEE Winter Conference on Applications of Computer Vision (WACV)*, 2017, pp. 520–529. [Online]. Available: <https://doi.org/10.1109/WACV.2017.64>
- [9] A. Vaswani *et al.*, “Attention Is All You Need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. [Online]. Available: <https://arxiv.org/abs/1706.03762>
- [10] A. Dosovitskiy *et al.*, “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” *arXiv preprint arXiv:2010.11929*, 2020, [Online]. Available: <https://arxiv.org/abs/2010.11929>
- [11] A. Radford *et al.*, “Learning Transferable Visual Models From Natural Language Supervision,” in *International Conference on Machine Learning (ICML)*, 2021, pp. 8748–8763. [Online]. Available: <https://arxiv.org/abs/2103.00020>
- [12] X. Li and others, “Adapting Vision-Language Models for E-commerce Understanding at Scale,” in *Proceedings of the Association for Computational Linguistics*, 2024. [Online]. Available: <https://arxiv.org/abs/2602.11733>